

Pràctica 1: Inventari d'ens dependents de les Comunitats Autònomes d'Espanya (2017 fins actualitat)

Tipología i cicle de vida de les dades

Roger Bosch Mateo

Octubre de 2019

Context

Qualsevol ciutadà té dret a accedir a la informació sobre les diverses activitats públiques del país. La llei 19/2013 de transparència va aconseguir donar un gran pas cap a aquesta fita obligant a les administracions públiques a concedir aquesta informació de manera periòdica, gratuïta, estructurada i reutilitzable entre d'altres. A partir d'aquesta llei són molts els portals oferts per les entitats públiques que faciliten l'accés a tal informació: el portal del Govern d'Espanya, de Catalunya o de la diputació de Barcelona per posar uns quants exemples.

Són tantes les fonts de dades que no totes estan sempre accessibles de la millor manera per l'usuari. Un clar exemple és el portal d'inventaris d'ens dependents de les comunitats autònomes que permet únicament la visualització de l'informació de manera individual i en cap moment es pot descarregar, dificultant així l'accés a dita informació. Aquest *dataset* preten posar un petit gra de sorra per facilitar al ciutadà un accés de qualitat a la informació del portal.

Descripció del *dataset*

El portal d'inventaris d'ens dependents de les comunitats autònomes mostra informació de les 16 comunitats autònomes (Andalusia, Aragó, Principat

d'Astúries, Illes Balears, País Basc, Canàries, Cantabria, Castella la Manxa, Castella i Lleó, Catalunya, Extremadura, Galícia, Comunitat de Madrid, Regió de Múrcia, Navarra, La Rioja i País Valencià) i les dues ciutats autònomes (Ceuta i Melilla) d'Espanya. Per a cada comunitat autònoma, es mostren totes aquelles entitats que es consideren integrants de l'inventari d'ens de cada comunitat autònoma (Autogovern de la comunitat autònoma, organismes autònoms administratius, organismes autònoms comercials, organismes autònoms, entitats públiques empresarials, ens públics, consorcis, fundacions, altres institucions sense ànim de lucre, societats mercantils i universitats). Per a cada entitat es mostra informació, si existeix: de caràcter general, de les activitats que realitza, dels components que la formen, l'històric de noms oficials i de capital social.

Contingut

El dataset inclou cinc taules diferents: dades generals, activitats, components (i components alternatiu), històric de noms i històric de capital social. És a dir, no estem parlant d'un dataset amb un únic fitxer CSV que el pot representar ja que hi ha diverses relacions entre aquestes taules. En la Figura 1 es poden veure les associacions entre cadascuna d'aquestes taules.

Per cada
taula
descriure
atribut

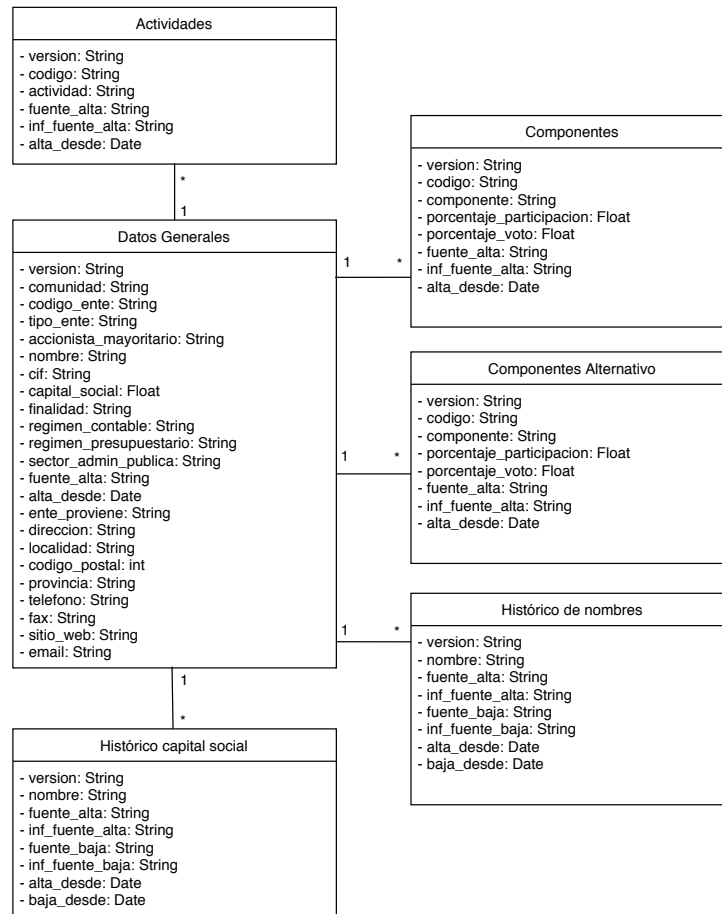


Figura 1: Esquema UML

Cal mencionar que per a cadascun dels ens hi ha la possibilitat de visualitzar la informació històrica, és a dir, veure la informació que hi havia sobre un ens en una data concreta. És per això que cadascuna de les taules presenta l'atribut *version* que donta quina versió de les dades s'està utilitzan segons la pàgina web. Seguidament per a cadascuna de les taules es descriuen els seus atributs:

Datos generales

- **version:** Indica la versió que representa la informació. Usualment cada

any presenta dues versions diferents la 01 i la 02. És per aixó que sol tenir els valors 200XX/0X.

- **comunidad:** Nom de la comunitat autònoma a la que pertany l'entitat.
- **codigo_ente:** Codi identificador de l'entitat.
- **tipo_ente:** Indica la tipologia de l'entitat segons la classificació esmentada en el README.md.
- **accionista_mayoritario:** Nom de l'entitat accionista majoritària si n'hi ha.
- **nombre:** Nom de l'entitat.
- **cif:** Identificador CIF de l'entitat.
- **capital_social:** Capital social de l'entitat. Pot ser nul.
- **finalidad:** Correspon a la finalitat insitucional, estatutària o societària atribuïda a cada entitat.
- **regimen_contable:** Indica el règim contable al que queda subjecte l'entitat.
- **regimen_presupuestario:** Fa referència al règim pressupostari aplicable a la entitat conforme a les normes aplicades.
- **sector_admin_publica:** Ofereix informació sobre la sectorització que, en el moment de la publicació, tenen vigents les entitats.
- **fuelle_alta:** Informació d'alta de l'entitat a l'inventari.
- **alta_desde:** Data d'alta de l'entitat.
- **ente_proviene:** Per aquelles entitats que tenen l'origen en una altre entitat, n'indica el nom d'aquesta.
- **direccion:** Indica la direcció de l'entitat.
- **localidad:** Indica la localitat on està situada l'entitat.
- **codigo_postal:** Indica el codi postal de la localitat de l'entitat.

- **provincia:** Indica la província on està situada l'entitat.
- **telefono:** Indica el telèfon de l'entitat.
- **fax:** Indica el fax de l'entitat.
- **sitio_web:** Indica la pàgina web de l'entitat.
- **email:** Indica el correu electrònic de l'entitat.

Actividades

- **version:**
- **codigo_ente:**
- **codigo:**
- **actividad:**
- **fuentes_alta:**
- **inf_fuentes_alta:**
- **alta_desde:** Date

Componentes

- **version:**
- **codigo_ente:**
- **codigo:**
- **componente:**
- **porcentaje_participacion:**
- **porcentaje_voto:**
- **fuentes_alta:**
- **inf_fuentes_alta:**
- **alta_desde:**

Componentes alternativo

- Falta veure

Histórico de nombres

- version:
- codigo_ente:
- nombre:
- fuente_alta:
- inf_fuente_alta:
- fuente_baja:
- inf_fuente_baja:
- alta_desde:
- baja_desde:

Histórico capital social

- version:
- codigo_ente:
- nombre:
- fuente_alta:
- inf_fuente_alta:
- fuente_baja:
- inf_fuente_baja:

- alta_desde:
- baja_desde:

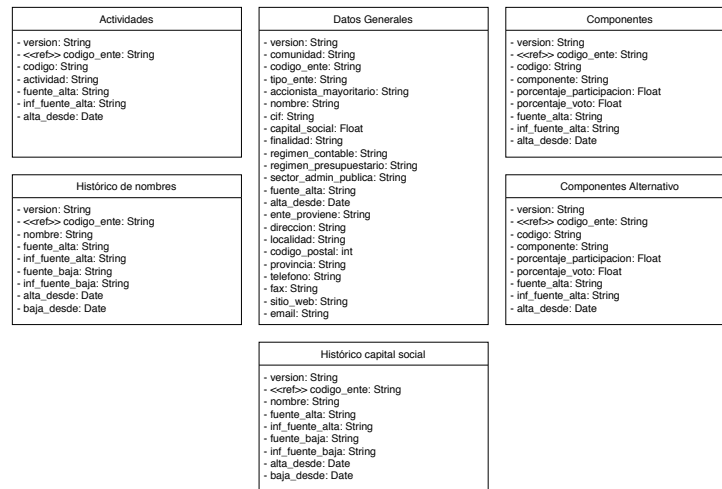


Figura 2: Diagrama de classes d'entitat

Solució tencològica

El portal web permet a l'usuari veure un per un per cada comunitat autònoma totes les entitats associades. A més d'un llistat genèric el portal proporciona un cercador, però aquest no és gens senzill d'utilitzar. Primer de tot perquè si vols veure els resultats de dues comunitats autònomes no pots: primer has de buscar-ne un i després l'altre. Segon, perquè els camps de cerca no són gens entenedors per un usuari casual fet que dificulta la feina a l'usuari.

Aquest *web scraper* creat facilita l'extracció de tota l'informació del portal utilitzant **Selenium**¹ per a Python. En la Figura 3 es pot veure el fluxe que es segueix per a la realització de l'scraping.

¹<https://selenium-python.readthedocs.io/installation.html>

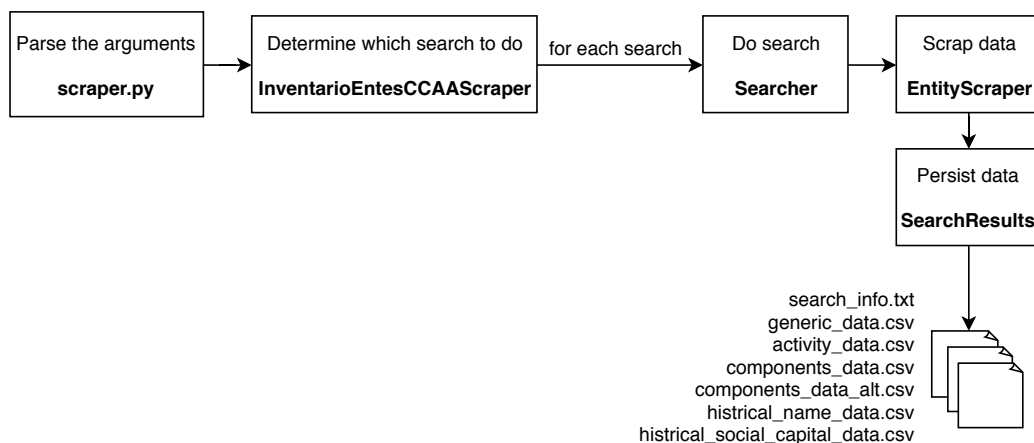


Figura 3: Fluxe de l'scraping

- **scraper.py**: És el fitxer que ha de cridar l'usuari per iniciar l'scraping. Admet una gran varietat de configuracions que permeten a l'usuari realitzar cerques d'una manera molt més senzilla que en el portal sense haver-se de preocupar de res. L'usuari podrà introduir la comunitat autònoma, província o tipus d'entitat entre d'altres i el programa se'n encarregarà de realitzar-lo. Hi ha una certa complexitat en les configuracions, i no ha sigut una tasca senzilla ja que en el portal no es mostra en cap moment informació sobre els camps que en tot moment són numèrics. Una descripció detallada dels arguments suportats amb exemples està disponible en el **README.md** del repositori de Github.
- **InventarioEntesCCAAScraper**: Una vegada tenim tots els arguments que defineixen la cerca que l'usuari desitja, s'han d'interpretar. Aquesta classe prendrà tots els arguments i determinarà quantes cerques s'han de realitzar i amb quins arguments. Per exemple un usuari en una mateixa cerca pot voler buscar informació sobre les societats mercantils i les universitats de la comunitat autònoma de Catalunya i la província de Viscaya. Per obtenir els resultats d'aquesta informació s'han de realitzar un total de 10 cerques degut a les limitacions del cercador:

– Les societats mercantils tenen quatre representacions en codi² se-

²Tots aquests codis no estan especificats en cap lloc del portal i han sigut extrets

gons les seves característiques "B-P", "X-P", "Z-P" i "F-P". Per cada tipus hem de realitzar una cerca diferents i tenim dues comunitats autònomes a cercar que són Catalunya i el País Vasc (on pertany Viscaya). Per tant amb les societats mercantils s'han de realitzar vuit cerques diferents.

- Les universitats estan representades únicament amb el codi "B-Wi" com tenim Catalunya i Viscaya hem de fer dues cerques més, fent un total de deu cerques.

En aquest punt cal considerar que l'*input* rebut per part de l'usuari és textual, mentre que el portal únicament accepta un codi preestablert. És per això que en aquest punt també es transformen els valors textuais als codis numèrics corresponents gràcies a l'investigació del significats d'aquests, com per exemple amb la traducció del nom de les províncies al seu codi [1].

- **Searcher:** Aquest classe prendrà els arguments definitius d'una de les cerques a realitzar: quina comunitat autònoma ha de seleccionar, quina versió o quin tipus d'entitat entre d'altres. Quan hagi introduït tots els valors realitzarà la cerca, n'extreurà tots els links a les entitats a obtenir informació i per cadascun dels enllaços invocarà a *EntityScraper* perquè n'extregui la informació.
- **EntityScraper:** A partir del link realitzarà un *request* i n'extraurà la informació disponible per aquesta entitat. En aquest punt cal esmentar que tot i que en la majoria dels casos l'estructura és la mateixa, en algunes entitats aquesta canvia. És el cas de l'informació genèrica que en alguns casos és mostra desordenada i per tant el *path* al valors dels atributs és diferent i el cas de la taula "*Components*" que a vegades mostra informació completament diferent (és per això que s'ha creat la taula *components_alt_data*).
- **SearchResults:** Finalment s'exporten totes les dades en un total de sis fitxers diferents seguint l'estructura presentada en la Figura 2. També crea el fitxer *search_info.txt* que conté informació de cadascuna de les cerques realitzades per obtenir l'informació final. Aquest fitxer és molt útil a mode de traçabilitat dels resultats.

manualment a base de cerques.

Adicionalment el programa aplica algunes tècniques per evitar ser bloquejats durant la seva utilització:

- Amb l'ús de *User-Agent Spoofing* cada vegada que es realitza un *request* el *header* és canviat per un altre totalment diferent, gràcies a la llibreria de Python `fake-useragent`³ que proporciona una base de dades amb dades reals.
- Per evitar saturar el servidor es calcula el temps que s'ha tardat en rebre l'últim *request* realitzat i no es realitza el següent fins que hagin passat deu vegades aquest temps.
- El comportament de l'scraping varia en certs punts:
 - Quan la classe *InventarioEntesCCAAScraper* determina quines cerques s'han de realitzar, aquestes no es realitzen seqüencialment sinó de manera aleatòria. Seguint l'exemple donat si no es realitza aleatoriament primer es realitzarien totes les cerques de Catalunya i després les del País Vasc. Al aleatoritzar-ho fem que aquestes s'intercalin evitant així realitzar sempre el mateix ordre.
 - La mateixa acció realitza la classe *Searcher* al cridar *EntityScraper*. Els links no es segueixen seqüencialment.

Agraïments

Els propietaris d'aquestes dades són les comunitats i ciutats autònomes i l'Administració General de l'Estat. Les dades recollides en l'inventari són subministrades per totes les comunitats i ciutats autònomes a la "Direcció General de Coordinació Financera amb les Comunitats Autònomes" els quals mantenen aquestes dades actualitzades permanentment en el portal [2].

Inspiració

Aquest *dataset* és de gran interès per entendre millor les comunitats autònomes. De manera global a tota Espanya i per cada comunitat autònoma podem estudiar tots els ens dels que disposa i obtenir informació interessant sobre aquesta:

³<https://pypi.org/project/fake-useragent/>

- Quantes entitats dependents de les comunitats autònomes hi ha? Quin tipus d'entitats predominen globalment, en cada comunitat, en cada província o fins i tot en cada ciutat?
- Quina comunitat autònoma presenta a dia d'avui més capital social segons totes les seves entitats i com ha anat evolucionant des de 2007 fins a l'actualitat?
- Quin tipus d'entitat sol presentar més canvis de nom al llarg de la història? Són canvis de nom significatius o petites variacions?
- Hi ha algú que tingui participació en diverses entitats? Té el control sobre aquestes (més 50%) o no?
- A més, permet obtenir informació de contacte de cada entitat (telèfon, pàgina web, correu electrònic...) i el seu identificador (cif), que pot ser utilitzat per agregar dades d'altres fonts d'informació.

Cal dir que aquests són només uns quants exemples de preguntes que podrien ser respostes amb el dataset, però de ben segur que a mesura que aquestes es responen moltes altres preguntes de gran interès sorgeixen.

Llicència

La llicència resultant sobre la que es llibera el *dataset* és ***Public Domain License (CC0)***, perquè qualsevol individu pugui copiar, modificar, distribuir i fer comunicació pública d'aquesta fins i tot per fins comercials. Aquesta elecció es basa en la naturalesa de les dades i l'*Open Data*. Com ja s'ha comentat qualsevol individu ha de tenir accés a aquesta informació de caràcter públic i aquest *dataset* és un pas cap a aquest objectiu permetent de manera senzilla la reutilització d'aquestes dades, cosa que el portal no permet.

Contribucions

Les contribucions en aquest projecte són les següents:

Contribucions	Signa
Recerca prèvia	Roger Bosch Mateo
Redacció de respostes	Roger Bosch Mateo
Desenvolupament codi	Roger Bosch Mateo

Taula 1: Taula de contribucions al projecte

Referències

- [1] "Relación de provincias con sus códigos", Instituto Nacional de Estadística (INE). Obtingut de https://www.ine.es/daco/daco42/codmun/cod_provincia.htm
- [2] "Notas relativas a la información contenida en el inventario de entes integrantes de las comunidades autónomas". Obtingut de <https://serviciostelematicosext.hacienda.gob.es/SGCIEF/PubInvCCAA/Ayuda/NOTAS%20INFORMATIVAS.pdf>